

# ▮ Introducción a scikit-learn

**scikit-learn** (comúnmente conocido como `sklearn`) es una de las bibliotecas más populares de Python para **Machine Learning**. Está organizada en **módulos** especializados en diferentes tareas, lo que permite estructurar y reutilizar código de forma eficiente.

---

## ▮ Conceptos clave

- **Módulo:** Archivo `.py` que contiene código Python.
- **Paquete:** Colección de módulos. Debe incluir un archivo especial llamado `__init__.py` para ser reconocido como tal por Python.
- **Biblioteca:** Conjunto de paquetes que proveen funcionalidades específicas, como lo hace `scikit-learn` para el aprendizaje automático.

---

▮ **Resumen:** `scikit-learn` es una **biblioteca** → compuesta por **paquetes** → que a su vez contienen **módulos**.

---

# ▮ Principales módulos de scikit-learn

## 1. Preprocesamiento de datos

- `sklearn.preprocessing` : Transformación y normalización de datos.  
**Ejemplos:** `StandardScaler` , `MinMaxScaler` , `OneHotEncoder` , `LabelEncoder` .
- `sklearn.impute` : Manejo de valores faltantes.  
**Ejemplo:** `SimpleImputer` .
- `sklearn.feature_selection` : Selección de características **Ejemplo:** `SelectKBest`, `RFECV`

## 2. Selección y extracción de características

- `sklearn.feature_selection` : Métodos para seleccionar características relevantes.  
**Ejemplos:** `SelectKBest` , `RFECV` .
- `sklearn.feature_extraction` : Extracción de características de texto e imágenes.  
**Ejemplos:** `CountVectorizer` (para texto), `TfidfVectorizer` .

## 3. Modelos supervisados

- `sklearn.linear_model` : Modelos lineales.  
**Ejemplos:** `LinearRegression` , `LogisticRegression` , `Ridge` , `Lasso` .
- `sklearn.tree` : Árboles de decisión.  
**Ejemplos:** `DecisionTreeClassifier` , `DecisionTreeRegressor` .

- `sklearn.ensemble` : Métodos ensemble.  
**Ejemplos:** `RandomForestClassifier` , `GradientBoostingRegressor` , `AdaBoost` .
- `sklearn.svm` : Máquinas de vectores de soporte (SVM).  
**Ejemplos:** `SVC` , `SVR` .
- `sklearn.neighbors` : Algoritmos basados en vecinos.  
**Ejemplos:** `KNeighborsClassifier` , `KNeighborsRegressor` .
- `sklearn.naive_bayes` : Modelos bayesianos **Ejemplos:** `GaussianNB` , `MultinomialNB`
- `sklearn.neural_network` : Redes neuronales básicas **Ejemplos:** `MLPClassifier` , `MLPRegressor`

## 4. Modelos no supervisados

- `sklearn.cluster` : Algoritmos de clustering.  
**Ejemplos:** `KMeans` , `DBSCAN` , `AgglomerativeClustering` .
- `sklearn.decomposition` : Reducción de dimensionalidad.  
**Ejemplos:** `PCA` , `TruncatedSVD` , `NMF` .
- `sklearn.mixture` : Modelos de mezclas Gaussianas **Ejemplo:** `GaussianMixture` .
- `sklearn.covariance` : Detección de anomalías **Ejemplo:** `EllipticEnvelope` .

## 5. Evaluación de modelos

- `sklearn.metrics` : Métricas de evaluación.  
**Ejemplos:** `accuracy_score` , `precision_score` , `confusion_matrix` , `roc_auc_score` .
- `sklearn.model_selection` : Validación y ajuste de hiperparámetros.  
**Ejemplos:** `train_test_split` , `cross_val_score` , `GridSearchCV` .

## 6. Utilidades generales

- `sklearn.pipeline` : Creación de flujos de procesamiento.  
**Ejemplo:** Pipeline para encadenar transformadores y estimadores., `ColumnTransformer`
- `sklearn.utils` : Funciones auxiliares.  
**Ejemplo:** `shuffle` (mezcla de datos), `resample`
- `datasets` : Datasets de prueba **Ejemplo:** `load_iris` , `make_classification`

## 7. Módulos Especializados (menos conocidos)

- `sklearn.cross_decomposition` : Modelos para datos multivariados **Ejemplo:** `PLSCanonical` .
- `sklearn.isotonic` : Regresión isotónica **Ejemplo:** `IsotonicRegression` .
- `sklearn.kernel_approximation` : Aproximación de kernels **Ejemplo:** `Nystroem` , `RBFSampler` .

- `sklearn.manifold` : Reducción de dimensionalidad no lineal **Ejemplos:** `TSNE` , `MDS` .
- `sklearn.multiclass` : Clasificación multiclase **Ejemplo:** `OneVsRestClassifier` .
- `sklearn.multioutput` : Modelos para múltiples salidas **Ejemplo:** `MultiOutputRegressor` .

---

## □ ¿Cómo verificar todos los módulos disponibles?

Puedes listar todos los submódulos de `scikit-learn` en Python con:

```
import sklearn
help(sklearn) # Muestra la documentación con todos los módulos
```

---

## □ Ejemplo práctico usando varios módulos

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score
from sklearn.pipeline import Pipeline

# Cargar datos
data = load_iris()
X, y = data.data, data.target

# Dividir datos en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3)

# Crear un pipeline con escalado y modelo
pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('classifier', RandomForestClassifier(n_estimators=100))
])

# Entrenar y predecir
pipeline.fit(X_train, y_train)
y_pred = pipeline.predict(X_test)

# Evaluar
print(f"Accuracy: {accuracy_score(y_test, y_pred):.2f}")
```

## Salida:

```
Accuracy: 0.96
```